

Item Silk Road: Recommending Items from Information Domains to Social Users

通讯作者: [何向南](#)

会议信息: SIGIR 2017, 链接: <http://dl.acm.org/citation.cfm?id=3080771>

Abstract

网络中存在用户-物品的交互信息, 而用户之间的交互称为社交信息, 两者是异构的。我们可以通过横跨两者的共同用户建立桥梁, 完成从信息领域到社交领域用户的物品推荐。现有的跨领域推荐系统中, 所有的数据属性都是同构的, 或者是完全重叠的。据此, 本文提出了一个神经网络社交协同排序算法 (Neural Social Collaborative Ranking, NSCR), 通过桥梁用户把两个异构数据之间“串联”起来。

Keywords

跨领域推荐, 深度协同过滤, 神经网络, 深度学习

Introduction

在线平台, 一种像网购电商网站有许多信息导向的用户-物品交互数据, 另一种如社交网络, 刻画并强调用户之间的交互信息。根据口耳相传的道理, 用户在选择商品时, 也会受到好友的推荐和好友们的意见影响。表面上看两个领域中的联系并不紧密, 但是通过某些同时活跃在这两个领域中的用户, 我们可以建立一座桥梁, 正如我们所说的丝绸之路一般, 把关系和信息传递过去。

跨领域社交推荐, 即从信息领域选择合适的物品, 向另一个社交网络中的其他用户推荐。目前的困境主要有两方面:

- 桥梁用户较少, 活跃在两个领域的用户比例约为10%
- 虽然信息领域信息充足, 但和社交领域相关的信息少

本文提出的NSCR解决方案基于

- 神经网络协同过滤, 采用一种改进的pairwise pooling策略, 刻画更好的用户-物品的低维特征表示
- 图正则, 通过桥梁用户在信息领域的embedding, 向社交领域传播, 使得亲密的朋友具有相近的特征表示, 意味着他们有相似的喜好

Problem Formulation

信息领域 M_1 , 用户集合 U_1 , 物品集合 I , 他们之间的交互 (打分) 为 Y_{ui} , 此外这中间还有一些关于用户和物品的辅助特征信息, 分别是用 G_u 和 G_i 表示; 在社交领域 M_2 , 有用户集合 U_2 , 和与之对应的社交关系 S 。桥梁用户定义为 $U = U_1 \cap U_2$ 。

输入: 信息领域下的 U_1, I, Y, G_u, G_i , 社交领域下的 U_2, S , 且满足 $U_1 \cap U_2 \neq \emptyset$

输出: 一个个性化的排序函数, 对于社交领域下的某个用户 u' , 给出信息领域下的某个物品 i 的喜好程度, 即 $f_{u'} : I \rightarrow \mathbb{R}$

My possible solution

同样抓住两个领域的共享用户，从信息领域（rating matrix）中通过model-based filtering（当然可以选择更为优秀的NNMF、NCF方法），学习到信息领域下 \mathcal{I} 用户的向量表示 \vec{u} 和物品的表示 \vec{p} 在社交领域 \mathcal{S} ，这里面的用户 u_s 可以表示为他在信息领域有信息的朋友的向量表示的（加权）平均，形式化可以表示为：

$$\vec{u}_s = \sum_j w_{js} \times \vec{u}_j \text{ for all } u_j \in \mathcal{I} \cap \mathcal{S} \text{ and } u_j \text{ is a friend of } u_s \text{ in } \mathcal{S}$$

这里的 w_{js} 是一个归一化之后的权重，通常是 $1/u_s$ 的好友个数，或者可以选择好友关系强度这类的系数。

得到仅仅在社交领域出现的用户 u_s 的表示后，重新回到信息领域视角下，把这个学习到的向量表示和物品的向量表示放在一起，通过 model-based filtering 模型，用 $f(\vec{u}_s, \vec{p}_i)$ 评估推荐的概率。

Motivations

在单个领域的视角下，喜好程度预测根据给定的用户和物品给出，抽象化表示为 $\hat{y}_{ui} = f_{\Theta}(u, i)$ ，像 model-based filtering 方法，用户和物品都表示为一个向量，映射函数 f 通常选取向量内积。虽然简单，但行之有效。换一个角度来看，内积操作其实是对用户和物品的向量对应位相乘得到 \vec{h} 再把每个分量加和起来，将 \vec{h} 视作输入层，就像是一个单层神经网络，模拟了一个 sum 函数的操作。这样的模型忽略了在跨领域的表示向量之间的关联性，简单的按位求和显然也无法体现协同关系。

NSCR Model

核心问题是，如何把两个领域之间的用户、物品的表示向量融合在同一个向量空间中。NSCR模型在两个领域分别依次学习向量表示，通过共享用户的表示传递，保证在同一个向量空间中。模型的优化目标定义为：

$$\mathcal{L} = \mathcal{L}_I(\Theta_I) + \mathcal{L}_S(\Theta_S)$$

\mathcal{L}_I 和 \mathcal{L}_S 分别是在两个领域上的损失， $\Theta_I \cap \Theta_S$ 非空保证了桥梁用户的特征向量是共享的，即在两个领域中是一致的。

Step 1：使用协同过滤方法最小化 \mathcal{L}_I

Step 2：通过半监督学习方法，利用Step 1中的桥梁用户表示，得到社交领域中的非桥梁用户的表示

Learning of Information Domain

与传统的只采用的observed data，即用户 u 和物品 i 是明确的有 $y_{ui} = 1$ 进行学习不同的是，使用了 pairwise 策略（其实就是负采样），训练和学习过程中还会使用到一些非观测数据，也会有 $y_{uj} = 0$ 的样例，最终的最小化： $\mathcal{L}_I = \sum_{(u,i,j) \in O} (\hat{y}_{ui} - \hat{y}_{uj} - 1)^2$

其二，增加了额外的辅助信息 G_u, G_i 刻画更为全面与准确的特征。以用户角度为例，假设有 V_u 个用户附属特征 g_t^u （通过 embedding 方法表示），输入层通过线性 pairwise pooling 完成信息融合：

$$\vec{v}_u = \varphi_{pairwise}(u, g_t^u) = \sum_{t=1}^{V_u} u \odot g_t^u + \sum_{t=1}^{V_u} \sum_{t'=t+1}^{V_u} g_t^u \odot g_{t'}^u$$

物品的表示也是类似，通过这样的操作得到 MLP 的输入层： $[\vec{v}_u \odot \vec{v}_i]$ ，MLP 输出为预测的喜好 \hat{y}_{ui}

Learning of Social Domain

首先，在社交领域内，定义了结构一致性的损失，即认为社交网络中的相邻节点（好友）的表示应该接近，从而：

$$\theta(U_2) = \frac{1}{2} \sum_{u_1, u_2 \in U_2} s_{u_1, u_2} \left\| \frac{\vec{v}'_{u_1}}{\sqrt{d_{u_1}}} - \frac{\vec{v}'_{u_2}}{\sqrt{d_{u_2}}} \right\|^2$$

其中， s_{u_1, u_2} 为用户 u_1 和 u_2 的社交关系强度， d_u 表示用户网络节点的出度，进行了平滑，因此也称 Smooth 损失

另一方面，对于桥梁用户来说，应该使得社交视角下的表示与信息领域的表示尽可能相近，因此定义拟合（Fitting）损失：

$$\theta(U) = \frac{1}{2} \sum_{u \in U} \left\| \vec{v}'_u - \vec{v}_u^{(0)} \right\|^2$$

这里的 $\vec{v}_u^{(0)}$ 是来自信息视角下的向量表示，我们的学习目标是社交视角下的表示： \vec{v}'_u ，

从而定义总的损失： $\mathcal{L}_S = \theta(U_2) + \mu\theta(U)$

最终，通过社交视角下得到的用户表示 \vec{v}'_u 与信息视角下的物品表示 \vec{v}_i 作为 MLP 的输入，得到喜好预测 $\hat{y}_{u', i}$

Tips: 实际训练过程中，也是通过负采样，假设一些没有社交关系的用户之间的社交强度为0.

Experiments

Dataset

信息领域的数据集来自 Trip.com，将原本的rating转换为0/1，即 rated/not rated，社交关系来自与之相关的Facebook、Twitter社交网络

评价指标采用 AUC 和 Recall@K 验证

Model Comparison

NSCR模型比state-of-art更好，Twitter上的表现差于 Facebook，是由于Twitter上的桥梁用户少

相比简单的PopItem、MF推荐，不考虑社交数据和其他辅助数据，NSCR具有更好的表现，且社交网络正则（Smooth平滑策略）能够有效地防止整个社交网络仅被活跃用户主导

对于其他的附加属性，也体现出用户、物品之间的特征相似情况，通过特征的pooling层融合，有效减少了embedding的维度，缓解过拟合

Model Analysis

Dropout策略：在 pairwise pooling 层设置 dropout 能进一步提升性能，缓解过拟合

\mathcal{L}_S 中的超参 μ ：刻画了社交数据的贡献，调和 fitting 损失和 smooth 损失

MLP隐藏层数：符合经验，太少性能不好，多一些则性能提升，多到一定程度却也提升有限，且同时带来时间、内存的开销增长（进而发生过拟合，反而下降？）

embedding size：更大的embedding size 能显著提升向量的表示能力，但损害了模型的泛化能力，引起训练集上的过拟合

Related Works

Social Recommendation

用户的决定受到他的朋友观点和行为的影响，可以把这种影响带入推荐系统的预测过程中，作为一种考虑因素。以往的研究都基于同一视角下的用户-物品以及用户-用户社交网络数据，本文却是从另一个外部平台上获取社交数据

Cross Domain Recommendation

通常做法是使用辅助信息对用户和物品建模，这些辅助信息也是同构的。而真正的交叉领域推荐，主要有两个方向：

- 用户、物品在各个独立的领域中有多种表示，丰富它们的特征。如果用户、物品在各个领域之中有交叉，可通过共享的用户或物品向量空间联系起来
- 从某些领域学习出一些用户-物品交互的规律、知识，相似地迁移到另一个领域（第一次听说，很玄）

Conclusion

本文从传统的推荐系统的信息领域出发，向外部的、异构的社交用户进行物品的推荐，由 NSCR 模型融合两个领域的信息，由桥梁用户进行联系，向不同领域的用户进行推荐。本文最重大的发现在于：社交信息隐含着用户的偏好，即使是不同领域的用户。

本文存在局限性：所选的数据集规模不大，泛化能力待考证，因此，也未考虑一些冷启动用户。